

面向噪声标签数据的细粒度图像识别鲁棒微调

技术方案报告（初赛）

全球校园人工智能算法精英大赛 · 算法挑战赛

2026 年 6 月 15 日

1 算法概述

本方案面向**标签含噪**条件下的细粒度图像识别，在严格遵守赛题约束（骨干强制为 OpenAI CLIP ViT-B/32、单模型单推理、禁止集成、不宜全参数微调）的前提下，设计了一条“**数据去噪—鲁棒微调—推理校正**”的完整流水线。核心思路是：先用冻结骨干的特征做 **kNN 邻域一致性去噪**与**教师-kNN 共识伪标签**，把含噪训练集转化为带连续可靠性权重的干净化数据；再以参数高效的 **LoRA 微调**（注入 attention+MLP、448 分辨率、EMA、强增强）适配下游任务，全程采用**先划分再统计**的严格验证协议杜绝标签泄漏；最后在推理端引入**多尺度 TTA**与**均衡先验 logit 校正**（利用“测试集类别均衡”这一已知事实），并用 **Uniform Model Soup**（同架构权重平均）进一步降方差。

方案的主要特点是**全自动、可复现、合规**：噪声筛选无人工清洗环节，关键超参经系统化对比实验选定。本地严格协议下，主指标（kNN 一致性中带准确率）从基线 0.878 提升至模型汤的 0.9267；线上整体 Top-1 准确率经多版迭代显著提升。方案对计算资源友好（8GB 显存可完成全流程），并具备跨阶段（复赛/半决赛长尾、更多类别）的可迁移结构。

2 实现方案

2.1 解题思路与总体流程

赛题的本质矛盾是：训练标签含大量噪声（错标、弱相关、难样本），而直接监督微调会让模型**过拟合噪声、破坏 CLIP 预训练先验**。因此我们从“数据”和“模型”两个层面联合优化：

1. **特征提取**：冻结 CLIP ViT-B/32，水平翻转 TTA 平均、L2 归一化，缓存全量特征；
2. **噪声处理**：kNN 一致性打分 → 按类保留 → 教师头训练 → 共识伪标签回收 → 连续可靠性加权；
3. **LoRA 微调**：在冻结骨干上注入低秩适配器，按可靠性加权的软目标训练；
4. **推理**：多尺度 TTA + 均衡先验校正 + 模型汤，生成单模型单推理流程的预测。




图 1: 整体流水线: 特征提取 → 噪声处理 → 鲁棒微调 → 推理校正 → 单模型提交。

2.2 数据集处理

数据概况。 初赛数据集含 500 个自然动植物细粒度类别、103 218 张训练样本 (含标签噪声)、24 967 张测试样本 (人工精确标注、类别均衡)。部分图片存在文件截断, 统一用 PIL 的 `LOAD_TRUNCATED_IMAGES` 容错读取。

噪声水平刻画。 以冻结特征做 kNN ($k = 16$, 余弦相似度) 邻域一致性扫描, 统计训练集噪声强度: 一致性 < 0.3 的样本占 **42.0%**, < 0.5 占 59.1%。结论: 噪声水平高, 但 **低一致 $\neq$ 必然错标** (细粒度难样本也会低), 因此激进过滤有害, 需用**连续加权**而非硬删除。

严格验证协议 (防泄漏)。 先按类别分层划分训练/验证集 (90/10, `seed=42`), 所有标签驱动的统计 (kNN、样本筛选、教师训练、伪标签) 只使用训练分区; 验证样本只作为查询去检索训练图库, 绝不参与教师训练或模型初始化。这修正了早期 “划分前用全量标签筛选” 导致的验证指标乐观偏差。

kNN 一致性去噪。 对样本 i , 在训练图库中取其 k 近邻 $N_k(i)$, 相似度加权的邻域标签一致性定义为

$$a_i = \frac{\sum_{j \in N_k(i)} w_{ij} \mathbb{I}[y_j = y_i]}{\sum_{j \in N_k(i)} w_{ij}}, \quad w_{ij} = \max(0, \cos(f_i, f_j)). \quad (1)$$

按类保留一致性最高的 ρ 比例 (**keep-ratio**, 最终取 $\rho = 0.90$) 作为可信样本, 并对一致性高于阈值的样本无条件保底, 得到保留掩码。

教师-kNN 共识伪标签。 在保留样本上训练一个余弦分类教师头, 得到每个样本的教师预测 $\hat{y}_i^T$ 、置信度 p_i 与 margin m_i 。对被丢弃的样本, 仅当 **教师预测与 kNN 多数投票一致且置信度 / margin 双双达标**时, 才以该共识标签回收为伪标签, 避免引入新噪声。

连续可靠性加权。 保留样本不做等权监督, 而是按三项乘积赋予连续权重:

$$r_i = a_i^\alpha \cdot p_i^\beta \cdot m_i^\gamma, \quad w_i = w_{\min} + (1 - w_{\min}) r_i, \quad (2)$$

使 “干净且容易” 的样本主导梯度、“可疑” 的样本被温和下调, 兼顾召回与抗噪。

2.3 算法设计与开发

骨干与适配器。 骨干为冻结的 CLIP ViT-B/32 (`timm vit_base_patch32_clip_224.openai`, OpenAI 官方权重)。在其 **attention** 与 **MLP** 线性层注入 **LoRA** (秩 $r = 32$, $\alpha = 64$), 仅训练约 5.1 M

参数（骨干 88M 全部冻结），既释放任务适配能力又抑制灾难性遗忘——符合赛题“不宜无约束全参数微调”的导向。

高分辨率。 将输入提升到 **448 px**（CLIP ViT-B/32 在 224 下仅 49 个 patch token，448 下增至 196 token），对位置编码做双三次插值（**官方权重本身不变，合规**）。对比实验表明 448 是分辨率甜点（512 因 batch 受限 + 位置编码过度插值反而下降）。

分类头与目标。 采用余弦分类头（特征/权重归一化），训练目标为按可靠性加权的交叉熵；以紧凑整数目标替代 $N \times C$ 稠密软标签矩阵以节省显存。亦实现了噪声鲁棒的 **广义交叉熵(GCE)** $L_q = (1 - p_y^q)/q$ 作为可选损失。

2.4 模型训练与优化

训练采用 **OneCycleLR**（总步数 = 轮数 × 每轮步数）、混合精度、梯度裁剪、**EMA**（衰减 0.999，用 EMA 权重做评估与推理）、**RandAugment** 强增强（细粒度裁剪范围 0.8-1.0）、早停与完整断点续训。最优配方：

LoRA(attn_mlp, r32) + EMA0.999 + RandAug + 448px + keep0.90 + 共识伪标签 (0.6/0.05)

关于训练轮数（重要负结果）。 由于 OneCycle 的学习率轨迹随总轮数缩放，短训练的“早峰值”是调度假象。我们专门做了 60 轮长调度诊断：噪声验证集整体准确率确在退火尾段（ep54）冲到更高，但线上榜分反而下降——说明该提升源于记忆脏验证标签，不迁移到干净测试集。结论：**训练轮数不是杠杆**，全量重训取验证峰值轮（约 4 轮）即可。

2.5 推理与测试

多尺度 TTA。 单模型多视角投票：对 {448, 512, 576} 三种尺度 × 水平翻转共 6 个视角的 logits 求平均（仍是单模型单推理流程，合规）。

均衡先验校正 (balanced)。 测试集类别均衡（每类约 50 张）是赛题给定事实，而原始预测分布严重偏斜（某类被预测 195 次/应 ≈ 50 ）。我们拟合每类对数偏置 b ，使 $\text{softmax}(z + b)$ 的类别边缘分布匹配均匀先验，再取 $\arg \max(z + b)$ 。该校正只用已知的均匀先验、不在测试数据上训练，是合规且“免费”的增益——线上最大提分点即来自 **多尺度 TTA + balanced** 的组合（记为 **tta_balanced**）。

Uniform Model Soup。 对同架构（r32/attn_mlp/448）的多个微调权重做均匀平均（ $\theta_{\text{soup}} = \frac{1}{N} \sum_i \theta_i$ ），得到单一权重、单次前向，属合规的单模型技术（区别于被禁止的输出层集成）。在 15 个候选上取 top-10 平均，本地主指标由最优单模型 0.9256 提升至 **0.9267**；而贪心汤（**Greedy Soup**）因逐个配对的近视性退化为单模型，不及均匀汤。

提交与校验。 预测输出为 **pred_results.csv**（图片名, 四位类别号），压缩为 zip；自动校验文件名与测试集完全匹配、类别号合规，再行提交。

3 实验与结果分析

所有候选在统一的严格协议下评测（90/10 分层划分，seed=42），主指标为 kNN 一致性中带准确率 mid_03_06（该带样本标签较可信但样本难、最具判别力）；整体准确率 noisy_all 作参考。

3.1 训练配方消融

表 1 给出从基线到最优配方的逐步演进。三条主线——分辨率（224→448）、数据召回（keep 0.75 → 0.90）、容量（LoRA $r_{16} \rightarrow r_{32}$ ）——逐步叠加均有增益，但增益递减。

表 1: 训练配方消融（val mid_03_06，严格协议）

配方	关键改动（相对基线）	mid_03_06
A 基线	attn-only LoRA r_{16} @224, 无 EMA	0.8780
B 容量 + 正则	attn+MLP LoRA + EMA + RandAug	0.8885
D 数据召回	B + keep0.85 + 放宽伪标签	0.9039
C 高分辨率	B + 448px	0.9091
+ rank32	C + LoRA r_{32}	0.9136
+ 数据召回	C + keep0.85（合并 C, D）	0.9184
+ keep0.90	上 + keep0.90	0.9233
最优单模型	448 + r_{32} + keep0.90 + 共识伪标签	0.9244
Uniform Soup	top-10 同架构权重平均	0.9267

3.2 模型汤对比

在 15 个同架构候选上评测取 top-10: **Uniform Soup** 主指标 0.9267 / 整体 0.7942，均超过最优单模型（0.9256 / 0.7907）；而 **Greedy Soup** 因逐对检验的近视性拒绝了全部追加、退化为单模型。说明本任务中“均匀平均多权重”的降方差比贪心选择更稳。

3.3 推理端杠杆

推理增强直接面向真实指标（整体准确率）。均衡先验校正把严重偏斜的预测分布（类计数标准差 ≈ 19 、单类最高 195/应 ≈ 50 ）拉回近均匀（标准差 ≈ 1.4 ）；多尺度 TTA + balanced (tta_balanced) 是线上实测最大提分点。

3.4 关键负结果与教训

长训练无效：60 轮长调度下，噪声验证集整体准确率在退火尾段升至 0.7941（高于短训练），但线上榜分反而下降——印证“噪声验证指标会因记忆脏标签虚高、与干净榜分背离”。因此最终方案不靠加轮数（全量重训取验证峰值轮约 4 轮），并以线上榜分为唯一选型判据。

4 算法创新点

- 1. 连续可靠性加权 + 共识伪标签：以 kNN 一致性 $\times$ 教师置信度 $\times$ margin 连续加权，配合 “教师 $\cap$ kNN 多数票” 的双重共识回收，兼顾召回与抗噪，优于硬阈值过滤。
- 2. 严格无泄漏验证协议：先划分再统计，使本地指标可信、可复现，避免选型偏差。
- 3. 均衡先验 logit 校正：将 “测试集均衡” 这一赛题事实转化为推理期合规增益，单刀显著提分。
- 4. 合规的单模型 “伪集成”：用 SWA / Uniform Model Soup 在权重空间降方差，规避禁集成红线，获得集成式收益。
- 5. 系统化对比实验框架：自动化串行跑候选配方、严格协议统一可比、结果自动汇总。

5 问题与思考

- 1. 本地指标 $\neq$ 线上指标：噪声验证集的整体准确率会因噪声记忆而虚高，与干净榜分方向相反（60 轮实验即被其误导）。教训：以线上榜分为唯一判据，本地指标仅作参考。
- 2. 工程稳定性：低系统内存下 DataLoader 锁页内存会僵死，全程加 `--no-pin` 规避；8 GB 显存下 448 高分辨率需控制 batch 防 OOM。
- 3. 回报递减与方向取舍：分辨率、数据召回、容量逐步叠加增益递减；及时排除无效方向（512 分辨率、长训练），把算力投向高 ROI 的推理端杠杆与模型汤。
- 4. 跨阶段泛化：复赛/半决赛存在长尾与更多类别，均衡先验校正与可靠性加权需针对非均匀/长尾分布做相应调整。

6 过程进度

阶段	时间	主要内容
数据准备	第 1-2 天	特征提取与缓存、噪声水平扫描、严格验证协议搭建
算法设计	第 2-4 天	kNN 去噪、共识伪标签、可靠性加权、LoRA 微调管线
训练与优化	第 4-7 天	多方案对比（分辨率/召回/容量/深度）、自动优化队列、最优配方选定
推理增强	第 6-8 天	多尺度 TTA、均衡先验校正、SWA / Model Soup
测试与验证	全程	单元测试 + 数值回归门、提交格式校验、线上榜分校准
文档与提交	第 8-9 天	技术报告、可复现代码与运行说明整理

7 团队分工

成员	角色	负责内容
(成员 A)	算法设计	去噪算法、可靠性加权、伪标签、损失设计
(成员 B)	模型训练	LoRA 微调、训练调优、对比实验、模型汤
(成员 C)	数据/工程	数据处理、特征缓存、推理与提交、复现工程
(成员 D)	文档撰写	技术报告、实验记录、结果汇总

(注：请按实际情况填写成员姓名与分工。)

8 解题参考资源

1. A. Radford, et al. *Learning Transferable Visual Models From Natural Language Supervision* (CLIP). ICML, 2021.
2. E. Hu, et al. *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR, 2022.
3. Z. Zhang, M. Sabuncu. *Generalized Cross Entropy Loss for Training Deep Neural Networks with Noisy Labels*. NeurIPS, 2018.
4. M. Wortsman, et al. *Model Soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time*. ICML, 2022.
5. P. Izmailov, et al. *Averaging Weights Leads to Wider Optima and Better Generalization* (SWA). UAI, 2018.
6. 近年关于噪声标签学习、鲁棒优化、样本筛选、表征一致性约束与灾难性遗忘抑制的代表性工作。