

面向噪声标签数据的细粒度图像识别鲁棒微调—技术报告

赛题: 全球校园人工智能算法精英大赛·算法挑战赛(初赛阶段) 骨干网络: CLIP ViT-B/32(OpenAI 官方预训练权重, timm vit_base_patch32_clip_224.openai)
日期: 2026 年 6 月 12 日

一、算法概述

本方案针对含噪标签条件下的细粒度图像识别任务, 提出一套“**特征空间自动去噪 + 软标签自训练 + 参数高效鲁棒微调**”的三段式微调框架。

首先, 利用冻结的 CLIP ViT-B/32 提取全部训练图像的视觉特征, 基于 **kNN 邻域标签一致性**对每个样本的标注可信度进行无监督评分: 若一个样本的近邻多数与其标签一致, 则该标注大概率正确。据此按类别自适应地保留各类前 75% 高一致性样本, 并对一致性极高的样本设置保留保底, 避免误删少数难样本。其次, 在筛选后的子集上训练余弦分类器作为教师, 对被过滤样本中模型预测置信度高者赋予**软伪标签**回收利用, 实现“过滤不浪费”。最后, 在视觉骨干的全部注意力层注入 **LoRA 低秩适配器** (仅 1.27M 可训练参数, 约占骨干参数的 1.4%), 骨干原始权重完全冻结, 分类头由教师模型热启动, 以软标签加权损失进行端到端微调。低秩约束从结构上限制了表征漂移, 兼顾噪声鲁棒性与预训练知识保留, 天然抑制灾难性遗忘。

由于训练标签含噪、无干净验证集, 本方案还设计了**按邻域一致性分带的本地验证协议**: 以“标签基本正确但样本困难”的中间一致性带 (0.3-0.6) 准确率作为核心选型指标, 有效规避了噪声验证集“奖励拟合噪声”的评估偏差。在本地留出集上, 最终模型相对无约束基线全集准确率提升约 9-15 个百分点, 整套流程 (含噪声筛选) 全自动、固定随机种子、一键复现。

二、实现方案

2.1 解题思路

赛题数据具有三个核心难点: 标签噪声重、类间差异细微 (细粒度)、无干净验证集。我们的总体思路是:

1. **不依赖人工清洗**——噪声甄别必须自动化、可复现 (满足赛题第五条算法设计要求);
2. **过滤要保守、回收要充分**——细粒度场景下“低置信样本”中混有大量“难而正确”的样本, 激进过滤会损伤表征 (实验证实 keep 50%/60% 全面劣于 75%);
3. **微调要受约束**——以 LoRA 低秩适配替代全参数微调, 从参数空间结构上限制对预训练知识的破坏;
4. **评估要去偏**——构建分带验证协议解决“用噪声标签评估模型”的悖论。

2.2 数据处理

- **数据概况**: 500 个细粒度类别, 103218 张训练图 (类内 201-213 张, 分布均衡), 24967 张测试图; 类别目录为纯数字编号, 无语义类名, 故未使用文本模态先验。
- **损坏容错**: 部分图片文件截断, 统一开启 PIL ImageFile.LOAD_TRUNCATED_IMAGES, 全量图片可正常读取。
- **特征缓存**: 冻结骨干对全量图片单次推理 (含水平翻转 TTA 取平均、L2 归一化), 缓存 768 维特征, 使后续所有去噪与头部实验在秒级完成, 支撑了高密度消融。

- **噪声扫描:** kNN (k=16, 余弦相似度加权) 邻域标签一致性统计显示, 42% 训练样本一致性 < 0.3, 21% < 0.1, 证实噪声水平较高。

2.3 算法设计与开发

第一阶段: kNN 邻域一致性选择。对每个训练样本, 在全体训练特征中检索 16 个最近邻 (排除自身), 以相似度加权计算近邻标签与自身标签的一致率。按类别取一致性前 75% 样本, 同时无条件保留一致性 0.7 的样本。按类自适应选择保证了筛选不会系统性偏向某些类别。最终保留 77494/103218 (75.08%)。

第二阶段: 教师训练与软伪标签回收。在保留子集上训练余弦分类器 (特征与权重均 L2 归一化、可学习温度, 对噪声更稳健)。训练完成后对被过滤样本推理, 预测置信度 0.7 者以预测类别构造平滑软标签、按置信度加权重新纳入训练 (标签平滑 0.1)。

第三阶段: LoRA 鲁棒微调。在 ViT 全部 12 层注意力的 qkv 与输出投影线性层注入 LoRA (秩 $r=16$, $\gamma=32$, dropout 0.05), 骨干原权重全部冻结; 分类头由第二阶段教师热启动。训练目标为软标签交叉熵的样本加权平均。数据增强采用 RandomResizedCrop(0.65-1.0) + 水平翻转 + 轻度 ColorJitter (噪声数据下避免重增强)。

2.4 模型训练与优化

- 优化器 AdamW, LoRA 参数 lr $2e-4$ (无权重衰减)、分类头 lr $1e-3$ (wd $1e-2$), OneCycle 调度 (10% warmup), 混合精度训练, batch size 192;
- 10 个 epoch, 单卡 RTX 5060 Laptop (8GB) 每 epoch 约 5 分钟, 总训练约 50 分钟, 工程成本低;
- 推理采用单模型 + 水平翻转 TTA (单一推理流程, 符合“禁止多模型集成”约束)。

2.5 测试与验证

分带验证协议 (核心方法论贡献): 按类分层留出 10% (10285 张) 作验证集, 并按验证样本自身的 kNN 一致性分为三带:

- 低带 (<0.3, 4308 张): 标签多为错标, **此带准确率高反而意味着拟合噪声;**
- **中带 (0.3-0.6, 2673 张): 标签基本正确但样本难, 区分度最高, 作为模型选型主指标;**
- 高带 (0.6, 3304 张): 接近饱和 (98%+), 仅作健康检查。

消融实验结果 (同一划分、同一随机种子):

方案	噪声全集	中带	高带
置信度两阶段选择 (复现的对照基线)	0.5840	—	—
纯 CE + 标签平滑 (无去噪)	0.6409	0.8058	0.9897
GMM 损失建模加权	0.5934	—	—
kNN 过滤 (keep 50%)	0.5928	0.7415	0.9840
kNN 过滤 (keep 75%) + 软标签自训练	0.6450	0.8182	0.9906
+ LoRA 微调 (最终方案)	0.7353	0.8887	0.9918

最终方案相对无去噪基线: 噪声全集 +9.4pt、中带 +8.3pt; 相对复现的置信度选择基线全集 +15.1pt。提交文件经自动化脚本校验 (文件名与测试集严格一致、四位类别编号、zip 规范)。

三、算法创新点

1. **kNN 邻域一致性去噪**: 完全在冻结 CLIP 特征空间进行, 无需训练即可对 10 万级样本在 2 秒内完成噪声评分; 按类自适应阈值 + 高一致保底的“保守过滤”设计, 避免了细粒度场景下难样本被误删——消融显示这是过滤策略成败的关键。
2. **“过滤不浪费”的软伪标签回收**: 被过滤样本经教师模型高置信重标注后以软标签、置信度加权方式回收, 在去噪与数据利用率之间取得平衡。
3. **分带验证协议**: 针对“无干净验证集”这一赛题核心困境, 提出按邻域一致性分带评估、以中带准确率选型的方法, 识别并规避了噪声验证集奖励噪声拟合的系统性偏差 (实验中多个“全集指标更高”的配置在低带暴露出噪声拟合迹象而被否决)。
4. **结构化抗遗忘**: LoRA 低秩约束 + 骨干冻结 + 教师头热启动三重机制保留预训练先验, 全部可训练参数仅 1.27M, 在 8GB 消费级显卡上即可完成训练, 方案对复赛/半决赛更大规模数据具备良好的可扩展性。

四、问题与思考

遇到的问题	分析与解决
噪声验证集上“不去噪的模型分数更高”, 去噪方法看似全部失效	定位为评估偏差: 噪声验证集奖励拟合噪声的模型。设计分带验证协议, 以中带为主指标后各方法优劣立判
激进过滤 (保留 50-60%) 反而全面掉点	细粒度任务中低一致性样本混有大量难而正确的样本; 改为保守过滤 (75%) + 高一致保底 + 软标签回收
GMM 损失建模、多轮自训练等经典方法收益不及预期	GMM 在细粒度 + 均衡分布下区分度不足; 多轮自训练低带准确率持续抬升 (拟合噪声迹象), 均未采用——经验: 方法选择须以去偏指标为准, 不迷信文献默认配置
Windows 下 DataLoader 验证阶段 worker 进程崩溃	系统内存不足 (每 worker 为独立进程约 1GB); 验证 loader 降为 2 worker 并持久化复用
EMA + mixup 组合掉点	训练总步数少 (~180 步), EMA decay 0.999 远未收敛; 短程头部训练不适用, 弃用
部分图片文件截断报错	按赛题提示开启 Pillow 截断容错, 全量可读

进一步优化方向: 全量数据 (含验证留出) 重训最终模型; 延长训练 (epoch 10 仍为 best, 未见过拟合); 以微调后特征迭代刷新 kNN 噪声评分 (特征-去噪交替优化); 复赛长尾场景下引入 logit adjustment 与类频感知的选样阈值; 取得线上分数后标定本地中带指标与线上准确率的相关性, 降低提交消耗。

五、过程进度

阶段	开始	结束	主要完成内容
数据准备	2026-06-11	2026-06-11	数据下载解压、完整性扫描、类别分布统计、冻结特征全量提取与缓存
基线构建	2026-06-11	2026-06-12	复现冻结特征 + 余弦头 + 置信度两阶段选样基线，首版提交文件生成
算法设计与消融	2026-06-12	2026-06-12	建立分带验证协议；两轮共 17 组消融 (kNN/GMM/软标签/mixup/EMA/keep-ratio/多轮自训练)，锁定 kNN75+ 软标签配方
模型训练与优化	2026-06-12	2026-06-12	LoRA 微调管线开发、冒烟测试、10 epoch 完整训练 (中带 0.8887)
测试与提交	2026-06-12	2026-06-12	测试集推理 (翻转 TTA)、提交文件生成与自动化格式校验
文档撰写	2026-06-12	2026-06-12	实验记录 (EXPERIMENTS.md) 与本技术报告

六、团队分工

成员	角色	负责内容
(待填写)	算法设计	鲁棒微调框架设计、去噪策略与验证协议设计
(待填写)	编程开发	训练/推理管线实现、实验执行、工程优化
(待填写)	数据分析	噪声特征分析、消融实验结果分析
(待填写)	文档撰写	技术报告、实验记录、提交材料整理

七、解题参考资源

1. Radford A, et al. Learning Transferable Visual Models From Natural Language Supervision. ICML 2021. (CLIP)
2. Hu E J, et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.
3. Li J, et al. DivideMix: Learning with Noisy Labels as Semi-supervised Learning. ICLR 2020. (损失建模选样思想)

4. Guo Y, Gu X. JoAPR: Cleaning the Lens of Prompt Learning for Vision-Language Models. CVPR 2024.
 5. Zhang X, et al. TrustCLIP: Learning from Noisy Labels via Semantic Label Verification and Trust-aligned Gradient Projection. ACM MM 2025.
 6. Wortsman M, et al. Robust Fine-tuning of Zero-shot Models (WiSE-FT). CVPR 2022. (鲁棒微调与抗遗忘思想)
 7. 工具: PyTorch、timm、Pillow、NumPy; 预训练权重: OpenAI CLIP ViT-B/32 (经 HuggingFace timm 发布的官方权重)。
-

附: 复现命令

```
pip install -r requirements.txt
python main.py                                # 特征提取 (生成 outputs/cache)
python exp_head.py                            # 第一轮消融
python exp_round2.py                          # 第二轮调优
python finetune_lora.py --epochs 10           # LoRA 微调 (90/10 验证)
python finetune_lora.py --predict             # 生成 pred_results_lora.csv/zip
python check_submission.py --csv pred_results_lora.csv --zip pred_results_lora.zip
```

全流程固定随机种子 (seed=42), 噪声筛选环节完全由代码自动执行, 无人工清洗步骤。